Omara Ramos Leite

Raciocínios matemáticos das atividades.

① Tópico 1

Questão 1.

1.1

Trata-se de um exercício de otimização para alocação de múltiplos recursos, visando encontrar a melhor alocação de designers por projeto, considerando os seus "scores".

Assim, temos como definição de x:

x_{ij} = número de horas que o designer i dedica ao projeto j.

Onde:

$i = 1, 2, 3$ (designers)

$j = 1, 2, 3, 4$ (projetos)

- Função objetivo: maximizar o "score" total ponderado, ou seja, pontuação x horas

Logo:

$$\max Z = \max Z(\text{designer } 1) + \max Z(\text{designer } 2) + \max Z(\text{designer } 3)$$

Assim:

$$\max Z(\text{designer } 1) = 90x_{11} + 80x_{12} + 10x_{13} + 50x_{14}$$
$$\max Z(\text{designer } 2) = 60x_{21} + 70x_{22} + 50x_{23} + 65x_{24}$$
$$\max Z(\text{designer } 3) = 70x_{31} + 40x_{32} + 80x_{33} + 85x_{34}$$

Restrições: Cada designer possui no máximo 80 horas

$$d1: x_{11} + x_{12} + x_{13} + x_{14} \geq 80$$
$$d2: x_{21} + x_{22} + x_{23} + x_{24} \geq 80$$
$$d3: x_{31} + x_{32} + x_{33} + x_{34} \geq 80$$

- Demanda por horas de projeto (horas que os três designers precisam dedicar por projeto:

$$x_{11} + x_{21} + x_{31} = 70$$
$$x_{12} + x_{22} + x_{32} = 70$$
$$x_{13} + x_{23} + x_{33} = 85$$
$$x_{14} + x_{24} + x_{34} = 35$$

não negatividade:

$x_{ij} \geq 0 \quad \forall i, j$

Questão 2.

a) Funções univariadas (função que depende de uma única variável)

* Função exponencial: e^{ax} é convexa para qualquer a em R

uma função $f(x)$ é:
- convexa se $f''(x) \geq 0$
- côncava se $f''(x) \leq 0$

logo:

$$f(x) = e^{ax}$$
$$f'(x) = a e^{ax}$$
$$f''(x) = a^2 e^{ax}$$

obs: $\frac{d}{dx} e^{g(x)} = g'(x) e^{g(x)}$

Como $e^{ax} > 0$ e $a^2 \geq 0$

$$f''(x) = a^2 e^{ax} \geq 0 \quad \forall x$$

Portanto,

e^{ax} é convexa em $\mathbb{R}$

* Função potência: x^a é convexa para $a \geq 1$ ou $a \leq 0$ em R+
R+ (números reais não negativos)

Temos: $f(x) = x^a$, $x > 0$ (números reais não negativos)

$$f''(x) = a(a-1) x^{a-2}$$

Parte 1: x^{a-2}, como $x > 0$, $x^{a-2} > 0$

Parte 2: $a(a-1)$

→ testando os intervalos:
Quando $a \geq 1$, temos: Ex, $a = 1$, $1(1-1) = 1$ (positivo)
Quando $a \leq 0$, temos: Ex, $a = -1$, $-1(-1-1) = 2$ (positivo)
Quando $0 < a < 1$, temos: Ex, $a = 0{,}5$, $0{,}5(0{,}5-1) = -0{,}25$ (negativa)

Portanto:
A função $f(x) = x^a$ é convexa em R+ quando $a(a-1) \geq 0$
Isso acontece quando:
$a \geq 1$ ou
$a \leq 0$

* Função Potência = x^a é concava para $0 \leq a \leq 1$ em $\mathbb{R}_+$

Côncava $f''(x) \leq 0$

Parte 1 : $f(x) = x^a$, com $0 \leq a \leq 1$

$f''(x) = a(a-1)x^{a-2}$

Sabendo que $x > 0$ $(R+)$, $x^{a-2} > 0$, logo o sinal negativo depende de $a(a-1)$

Logo, para $0 \leq a \leq 1$

$a(a-1) \leq 0$

Assim = $f''(x) \leq 0$,

Portanto x^a é concava em $R+$

* Função logarítmica : $\log x$ é concava em $R++$

$f(x) = \log x$

Côncava = $f''(x) \leq 0$

$f'(x) = \frac{1}{x}$

$f''(x) = -\frac{1}{x^2}$

Para $R++$, $x > 0$, sendo que $x^2 > 0$

sendo $-\frac{1}{x^2} < 0$

Portanto $f''(x) < 0$

Assim, $\log x$ é côncava em $R++$

B) Função afim: $a^T x + b$ e simultaneamente convexa e côncava

Função afim: $f(x) = a^T x + b$

sendo $a^T x$ (combinação linear das variaveis)
b (constante)

obs: T (transposta)

gradiente $\nabla f(x) = a$

Hessiana $\nabla^2 f(x) = 0$

logo, se a Hessiana é $=0$, é uma constante, sendo, portanto, côncava e convexa ao mesmo tempo.

c) Função quadrática: $\frac{1}{2} x^T Q x + b^T x + c$ é convexa desde que $Q \geq 0$ (semidefinida positiva)

Função quadrática: $f(x) = \frac{1}{2} x^T Q x + b^T x + c$

Gradiente: $\nabla f(x) = Qx + b$

Hessiana: $\nabla^2 f(x) = Q$

Como para $Q \geq 0$ (semidefinida positiva)

logo
côncava ≥ 0

$\nabla^2 f(x) \geq 0$

d) Mínimos Quadrados: $\|y - Ax\|_2^2$ é sempre Convexa (desde que $A^T A$ seja sempre semidefinida positiva)

mínimos quadrados: $f(x)\ \|y - Ax\|^2$

a ideia da utilização dos mínimos quadrados na otimização é minimizar a soma dos erros ao quadrado

Para entender mais:

$$\min_x \|y - Ax\|^2$$

y = dados reais
Ax = modelo (fórmula a ser ajustada)
$y - Ax$ = erro
$\|\cdot\|^2$ = soma dos quadrados.

Assim, expandindo a equação:

$$\|y - Ax\|^2 = (y - Ax)^T (y - Ax)$$

$$= y^T y - 2y^T Ax + x^T A^T Ax$$

Gradiente

$$\nabla f(x) = -2A^T y + 2A^T Ax$$

Hessiana

$$\nabla^2 f(x) = 2A^T A$$

* Uma matriz Q é semidefinida positiva se:

$$z^T Q \geq 0 \text{, para todo vetor } z$$

admitindo $Q = A^T A$ para prova, temos:

$$z^T A^T A z = (Az)^T (Az) = \|Az\|^2$$ (produto de um vetor por ele mesmo)

logo $\|Az\|^2 \geq 0$, sempre